STUDI KASUS MENANGANI *PHISHING* URL MENGGUNAKAN *MACHINE* LEARNING

Pendahuluan

Saat ini, serangan *phishing* telah menjadi salah satu ancaman keamanan siber yang paling signifikan dan meluas secara global. Serangan ini biasanya menargetkan sektor-sektor vital seperti institusi keuangan, layanan *e-commerce*, dan media sosial dengan tujuan utama mencuri informasi sensitif pengguna, mulai dari kata sandi hingga data kartu kredit (Bourigue dkk., 2024). Dampak dari serangan ini sangat merugikan, tidak hanya menyebabkan kerugian finansial yang besar bagi individu dan perusahaan, tetapi juga memicu pencurian identitas (*identity theft*) dan merusak reputasi organisasi yang ditiru (Omari, 2023).

Tantangan utama dalam mendeteksi *phishing* adalah kecanggihan metode yang terus berkembang dari pihak penyerang. Mereka mampu memanipulasi struktur URL dan konten halaman agar terlihat identik dengan situs aslinya, sehingga sangat sulit dibedakan secara visual oleh pengguna awam (Bourigue dkk., 2024). Selain itu, metode pertahanan konvensional seperti penggunaan daftar hitam (*blacklist*) sering kali tidak efektif. Hal ini disebabkan karena penyerang terus-menerus membuat domain berbahaya baru yang belum terindeks di *database* keamanan, sehingga pendekatan statis tidak lagi memadai (Islam, 2023). Oleh karena itu, diperlukan pendekatan yang lebih adaptif dan otomatis, seperti penggunaan algoritma *Machine Learning*, untuk mendeteksi pola URL berbahaya secara lebih akurat dan *real-time*.

Beberapa penelitian terdahulu telah berupaya mengatasi masalah ini dengan berbagai algoritma. Omari (2023) dalam studi komparasinya menemukan bahwa tidak semua algoritma *Machine Learning* memiliki performa yang setara; metode *ensemble* seperti *Gradient Boosting* terbukti lebih unggul dengan akurasi 97.2% dibandingkan model tunggal seperti SVM yang mencapai 93.9%. Sementara itu, Bourigue dkk. (2024) menyoroti pentingnya penggunaan fitur yang komprehensif, di mana kombinasi fitur berbasis URL, konten, dan eksternal dapat meningkatkan kemampuan deteksi model secara signifikan.

Keterbatasan lain yang menonjol dalam penelitian-penelitian sebelumnya adalah kurangnya perhatian terhadap proses validasi model yang lebih ketat khususnya penggunaan *k-fold cross-validation* dan *hyperparameter tuning* yang sebenarnya sangat penting untuk memastikan stabilitas dan kemampuan generalisasi model. Banyak studi hanya menggunakan train test split sederhana tanpa optimasi parameter sehingga performa model berpotensi bias dan tidak menggambarkan kondisi yang sebenarnya. Selain itu, sebagian besar penelitian juga belum mengeksplorasi strategi reduksi fitur secara sistematis padahal dataset *phishing* URL umumnya memiliki fitur yang banyak dan kompleks. Tanpa proses seleksi fitur model membutuhkan komputasi besar sehingga tidak efisien jika diterapkan untuk deteksi *phishing* pada URL secara *realtime*. Selain itu, sebagian besar penelitian mengevaluasi performa model hanya menggunakan akurasi tanpa memperhatikan metrik lain seperti *Recall*, *F1-score*, dan *ROC-AUC*, yang lebih relevan untuk domain keamanan siber dengan tingkat *class imbalance* tinggi (Haq dkk., 2024; Barik dkk., 2025). Evaluasi yang terbatas ini dapat menyebabkan bias performa dan menurunkan efektivitas sistem deteksi dalam kondisi nyata.

Berdasarkan hal ini maka terdapat kebaruan dengan menerapkan *k-fold cross validation* dan *hyperparameter tuning* untuk memastikan hasil model lebih stabil dan tidak tergantung pada satu pembagian data saja (Barik dkk., 2025). Selain itu, penelitian ini juga melakukan penyaringan fitur dari dataset yang berisi 87 atribut untuk memperoleh fitur yang paling relevan. Proses reduksi fitur ini tidak hanya meningkatkan interpretabilitas model tetapi juga menurunkan beban

komputasi secara signifikan sehingga waktu deteksi menjadi jauh lebih cepat (Al Saedi & Flayh, 2023; Alzboon dkk., 2025). Dengan jumlah fitur yang lebih sedikit maka model dapat melakukan proses prediksi secara efisien dan lebih sesuai untuk implementasi *realtime* deteksi *phishing* pada URL.

Selain itu, penelitian ini melakukan evaluasi *multi-algoritma* secara sistematis dengan melibatkan model klasik seperti *Support Vector Machine (SVM)* dan *Decision Tree*, serta metode *ensemble learning* modern seperti *Gradient Boosting*, *XGBoost*, dan *LightGBM*. Pendekatan berbasis ensemble ini terbukti unggul dalam mendeteksi pola kompleks dan non-linier pada data phishing yang besar dan heterogen (Barik dkk., 2025; Haq dkk., 2024). Evaluasi dilakukan menggunakan metrik yang lebih komprehensif seperti *Precision*, *Recall*, *F1-score*, dan *ROC-AUC* serta *k-fold cross-validation* untuk memastikan stabilitas dan generalisasi model pada berbagai skenario data (Calzarossa dkk., 2023). Pendekatan ini tidak hanya memungkinkan identifikasi fitur yang paling berkontribusi dalam membedakan situs *phising* dari situs sah tetapi juga memberikan pemahaman yang lebih mendalam tentang perilaku model. Dengan demikian diharapkan penelitian ini memberikan kontribusi metodologis melalui pendekatan *end-to-end* yang lebih *robust*, stabil, dan interpretatif.

Penelitian Terdahulu

Terdapat sejumlah penelitian terdahulu yang membahas dan menganalisis performa berbagai algoritma *machine learning* dan teknik ekstraksi fitur dalam mendeteksi URL *phishing*. Hasil-hasil ini memberikan landasan penting bagi penelitian ini untuk melakukan perbandingan model secara lebih komprehensif dan sistematis.

Berdasarkan penelitian-penelitian pada Tabel 1 mengenai deteksi *phishing* menggunakan URL, terlihat pola umum bahwa sebagian besar penelitian menggunakan algoritma *machine learning* berbasis ensemble terutama Random Forest, Gradient Boosting, XGBoost, CatBoost, dan *stacking models*. Sebagian besar penelitian menunjukkan bahwa model Random Forest menjadi salah satu model terbaik dalam deteksi *phising* pada URL karena stabil, akurasinya tinggi, dapat menangani fitur yang saling berinteraksi, dan lebih tahan terhadap *noise*. Beberapa penelitian menunjukkan bahwa Random Forest menjadi model yang baik meskipun jumlah fiturnya sedikit. Selain itu, metode Gradient Boosting dan CatBoost juga menunjukkan performa yang tinggi terutama pada dataset besar dan kompleks sehingga banyak digunakan sebagai bagian dari model *ensemble*. Sementara itu, model LightGBM meskipun tidak selalu menjadi yang terbaik tetapi tetap menunjukkan performa yang kuat dan efisiensi tinggi dalam beberapa penelitian misalnya pada penelitian Ahammad dkk. (2022).

Jika dibandingkan terlihat bahwa penelitian yang menerapkan seleksi fitur seperti Mutual Information, ANOVA F-test, atau *filter based feature selection* menunjukkan peningkatan akurasi dan penurunan *false positive*. Penelitian oleh Bari dkk. (2025) menunjukkan bahwa *stacking* bekerja optimal setelah fitur *irrelevan* dihapus dan hasilnya akurasi bisa mencapai 98%. Penelitian ini juga didukung oleh studi Adane dkk. (2023) yang menunjukkan seleksi fitur dapat meningkatkan efisiensi dan menjaga akurasi tetap tinggi. Sebaliknya, penelitian yang menggunakan fitur sangat banyak tetapi tanpa seleksi fitur cenderung memiliki risiko *overfitting* atau waktu komputasi yang tinggi. Dari Tabel 1 terlihat bahwa ada perbedaan pendekatan antara penelitian yang hanya memakai fitur leksikal URL dan penelitian yang menggunakan fitur berbasis konten, domain, dan eksternal. Penelitian dengan fitur leksikal umumnya lebih cepat dan ringan namun bisa akurasinya tidak terlalu baik untuk URL *phising* yang sangat mirip dengan *legitimate* login URLs. Sebaliknya, penelitian yang menambahkan fitur konten dan domain mendapatkan performa lebih tinggi tetapi membutuhkan waktu komputasi yang lebih besar dan tidak selalu

cocok untuk deteksi secara *realtime*.

Penggunaan *machine learning* dalam deteksi *phishing* URL memiliki kelebihan karena dapat mengidentifikasi pola yang kompleks, memiliki akurasi yang tinggi, dan dapat bekerja pada dataset besar. Metode *ensemble* seperti Random Forest, Gradient Boosting, CatBoost, dan *stacking* dapat mencapai akurasi mendekati 100% pada dataset tertentu. Namun, kekurangannya adalah kebutuhan fitur yang lengkap, risiko *overfitting* jika tidak dilakukan seleksi fitur, dan sensitivitas yang menurun pada dataset dengan struktur URL yang sangat mirip. Penelitian oleh Bourigue dkk. (2024) menunjukkan bahwa DNN dapat mengungguli model klasik. Hal ini menunjukkan bahwa model tradisional dapat memiliki performa yang lebih rendah dibandingkan dengan model *deep learning*.

Hal ini menunjukkan bahwa deteksi *phishing* URL paling efektif ketika menggabungkan fitur yang informatif dan model *ensemble* khususnya Random Forest, CatBoost, dan *stacking*. Seleksi fitur juga sangat penting pada tahap *preprocessing* untuk meningkatkan akurasi dan efisiensi. Meskipun begitu, penelitian terbaru juga mulai menunjukkan bahwa *deep learning* mulai menjadi alternatif yang lebih unggul ketika tersedia dataset yang cukup besar. Hal ini menunjukkan bahwa tren umum penelitian mengarah pada penggabungan fitur leksikal, domain, dan web *content* dengan model *ensemble* atau *deep learning* untuk membuat sistem deteksi *phishing* URL yang cepat, akurat, dan stabil di berbagai jenis dataset.

Tabel 1. Penelitian Terdahulu

Judul dan Sitasi	**Variabel Penelitian**	**Data**	**Algoritma yang Digunakan**
A Filter-Based Feature Selection Framework to Detect Phishing URLs Using Stacking Ensemble Machine Learning (Bari dkk, 2025)	Penelitian ini memiliki total 26 variabel dari dataset satu, 33 fitur dari dataset dua, dan 61 fitur dari dataset tiga. Penelitian kemudian menjalankan ekstraksi fitur menjadi 5 kategori, yaitu Having IP, Redirect, Web Traffic, Iframe, dan Submit to Email.	Penelitian ini menggunakan 3 dataset dengan dataset pertama diambil dari penelitian Mohammad dkk (2012) dengan 4.898 URL. Dataset kedua berasal dari Buber (2019) sejumlah 73.575 URL. Dataset ketiga bersumber dari A. Hannousse (2020) dengan 11.430 URL.	Random Forest, KNN, Adaboost, XGBoost, Logistic Regression, Decision Tree, Gradient Boost Classifier, SVM, dan dua model *ensemble*: Stacking and Majority Voting.
Hasil Penelitian ini menunjukkan bahwa menggabungkan berbagai teknik *filter-based feature selection* (seperti menghapus fitur konstan, duplikat, quasi, fitur berkorelasi, serta menambahkan *Mutual Information* dan ANOVA) dapat meningkatkan performa deteksi phishing secara signifikan. Setelah fitur-fitur tidak relevan dibuang, model *machine learning* kemudian diuji, dan hasilnya adalah *stacking ensemble* (gabungan Gradient Boost, Random Forest, dan SVM) menjadi model paling akurat dengan *False Positive Rate* sangat rendah (1.31%–3.47%) dan akurasi tinggi (96.47%–98.17%) pada tiga dataset berbeda. Hasil ini menunjukkan bahwa pemilihan fitur yang tepat dapat mengurangi *noise* dan menurunkan *false positive*, sehingga model lebih akurat dalam mendeteksi phishing. Secara keseluruhan, pendekatan ini terbukti konsisten di berbagai ukuran dan jenis dataset dan menjadi dasar yang kuat untuk pengembangan sistem deteksi phishing yang lebih akurat dan stabil.			
Highly accurate phishing URL detection based on machine learning (Jalil dkk, 2022)	Penelitian ini memiliki total 100 fitur yang kemudian dipilih 30 fitur terbaik dan dibagi menjadi 3 kategori, yaitu: *Full URL-based features*, *Host-based features*, dan *Path area of the URL-based features*.	Penelitian ini menggunakan 6 dataset dari 3 sumber berbeda. Dataset pertama berasal dari Kaggle berisi 507.004 URL. Dataset kedua juga berasal dari Kaggle dengan jumlah 95.910 URL. Dataset ketiga, keempat, dan	Naive Bayes (NB), Logistic regression (LR), Support vector machine (SVM), K-Nearest Neighbor (KNN), Decision Tree (J48), AdaBoost (AB), Multilayer Perceptron

		kelima berasal dari penelitian Rao dkk (2019) dengan jumlah masing-masing 126.077 URL, 82.888 URL, dan 83.857 URL. Dataset keenam berasal dari Sahingoz dkk (2019) dengan jumlah 73.575 URL.	(MLP), dan Random Forest (RF)
Hasil Penelitian ini membuktikan bahwa *framework machine learning* berbasis fitur leksikal (hanya dari *string* URL tanpa *3rd party* atau konten halaman) mampu mendeteksi *phishing* URL dengan akurasi tinggi. Dengan mengekstraksi 30 fitur penting seperti panjang URL, *hostname*, path, entropy, kata mencurigakan, dan *brand-name matching* (TF-IDF), model diuji pada enam dataset berbeda menggunakan delapan algoritma ML. Hasilnya konsisten, yaitu Random Forest selalu menjadi model terbaik, mencapai akurasi 96,25% dan 94,65% pada dataset Kaggle, serta 92,2%–96,85% pada dataset lain. *Framework* ini efektif karena fitur yang dipilih relevan, prosesnya cepat (tanpa harus mengakses konten web), dan performanya stabil pada dataset besar maupun kecil. Meski begitu, pendekatan ini masih dapat salah untuk URL phishing yang menggunakan *hosting* gratis atau meniru visual situs target. Secara keseluruhan, model ini menunjukkan bahwa kombinasi fitur leksikal yang tepat dan Random Forest dapat memberikan deteksi phishing URL yang akurat dan efektif.			
Phishing URL detection using machine learning methods (Ahammad dkk., 2022)	Penelitian ini menggunakan 15 variabel, yaitu: domain name, keberadaan ip address (iya/tidak), keberadaan simbol @ (iya/tidak), panjang url, kedalaman url, keabnormalan posisi *double* slash (abnormal/normal), keberadaan https dalam domain (ada/tidak), keberadaan tanda *slash* (-) di domain (ada/tidak), *statistical report* (apakah domain ditemukan sebagai *phising* dengan jawaban iya/tidak), dns *record* (tidak ada/ada), web *traffic* berdasarkan *rank* alexa (*phishing*/aman), umur domain lebih dari 12 bulan (iya/tidak), masa aktif domain kurang dari 6 bulan (iya/tidak), jumlah subdomain, kepemilikan *multiple* pada subdomain (iya/tidak).	Dalam dataset ini terdapat 3000 URL, yang terdiri dari 1500 data URL *phishing* dan 1500 data URL *legitimate*. Data URL *phishing* dikumpulkan dari sebuah layanan bernama PhishTank. Layanan ini menyediakan data *phishing* secara kolaboratif melalui database informasi *phishing* di Internet. Sumber data ini berasal dari University of New Brunswick dengan jumlah URL *legitimate* sebanyak 35.300.	Random Forest, Decision Tree, Light GBM, Logistic Regression, dan SVM.

Hasil Dalam penelitian ini digunakan pembagian data untuk *training* dan *testing* sebesar 80% dari dataset untuk *training* dan 20% untuk *testing*. Dalam penelitian ini dataset diuji pada semua algoritma yang didapatkan hasil bahwa LightGBM memberikan hasil yang paling baik. Model LightGBM mendapatkan akurasi *training* sebesar 0,895 dan akurasi *testing* sebesar 0,860. Random Forest mendapatkan akurasi *training* sebesar 0,883 dan akurasi *testing* 0,853. Selain itu, Decision Tree mendapatkan akurasi *training* 0,880 dan akurasi *testing* 0,850. Logistic Regression mendapatkan akurasi *training* 0,878 dan akurasi *testing* 0,842. SVM mendapatkan akurasi *training* 0,871 dan akurasi *testing* 0,835. Hasil kurva validasi untuk model LightGBM menunjukkan skor *training* dan validasi meningkat stabil hingga kedalaman maksimum enam. Setelah itu, skor validasi sedikit menurun. Dengan demikian, dapat disimpulkan bahwa performa terbaik dicapai pada *max depth* lima.			
Machine Learning Techniques for Detecting Phishing URL Attacks (Mosa dkk., 2023)	Penelitian ini menggunakan 30 variabel, yaitu: keberadaan ip address (iya/tidak), keberadaan simbol @ (iya/tidak), panjang url (panjang/sedang/pendek), apakah URL merupakan URL pendek (iya/tidak), Keberadaan *double* slash berlebih (iya/tidak), jumlah subdomain (sedikit/sedang/banyak), keberadaan protokol HTTPS pada URL (aman/tidak/meragukan), panjang masa registrasi domain (pendek/panjang), favicon mengarah ke domain lain (iya/tidak), penggunaan port non-standar (iya/tidak), keberadaan "https" pada bagian domain (iya/tidak), persentase sumber daya eksternal yang dimuat halaman (tinggi/rendah), proporsi link anchor yang mencurigakan (banyak/sedang/sedikit), link mencurigakan pada script/metadata (iya/tidak), form handler mengarah ke domain lain (iya/tidak), keberadaan email mencurigakan di halaman (iya/tidak), URL tidak sesuai identitas domain (abnormal/normal), jumlah pengalihan halaman (banyak/sedikit), manipulasi status bar (iya/tidak), fitur klik kanan dinonaktifkan (iya/tidak), kemunculan popup mencurigakan (iya/tidak),	Penelitian ini menggunakan dataset yang berasal dari Kaggle dengan judul "*phishing* website dataset" yang dibuat oleh Maor Yatskan pada tahun 2019. Dataset ini berisi URL lebih dari 11.000 website. Setiap sampel terdiri dari 30 parameter *website* dan sebuah label kelas yang menunjukkan apakah website tersebut merupakan *phishing* atau bukan.	Neural Network, Naive Bayes, dan Adaboost.

	penggunaan iframe tersembunyi (iya/tidak), umur domain (lama/baru), keberadaan DNS record (tidak ada/ada), tingkat traffic website (tinggi/rendah), ranking halaman pada mesin pencari (tinggi/rendah), apakah website terindeks Google (iya/tidak), banyaknya link eksternal menuju website (banyak/sedikit), apakah domain masuk laporan phishing (iya/tidak).		
Hasil Hasil analisis menunjukkan bahwa model Adaboost memberikan performa terbaik di antara ketiga model dengan nilai akurasi tertinggi sebesar 95,43%. Selain itu, model Naïve Bayes memiliki akurasi sebesar 92,97% dan Neural Network dengan akurasi sebesar 90,23%. Nilai *precision* juga menunjukan bahwa model Adaboost memiliki nilai paling tinggi yaitu 95,70% yang menunjukkan bahwa model ini sangat baik dalam meminimalkan kesalahan ketika mengidentifikasi URL *phishing*. Dari sisi sensitivitas terlihat bahwa ketiga model memiliki performa sangat baik, dengan model Neural Network mencapai 97,21%, Naive Bayes sebesar 95,05%, dan Adaboost sebesar 96,12% yang berarti ketiganya dapat mendeteksi sebagian besar URL *phising* dengan akurat. Selain itu, Adaboost memiliki nilai spesifisitas dan F1-score terbaik dengan nilai masing-masing sebesar 95,43% dan 95,91% yang menunjukkan keseimbangan yang kuat antara kemampuan mendeteksi *phishing* dan meminimalkan false positif.			
A Comparison of Machine Learning Models Based on Feature Variations for Phishing URL Detection (Prakongsin & Kanjanasurat, 2025)	web_traffic, google_index, domain_age, LargestLineLength, LineOfCode, NoOfSelfRef, ratio_extHyperlinks, ratio_intHyperlinks, nb_hyperlinks, page_rank	Dataset dari Mendeley (Hannousse & Yahiouche, 2021): 11.430 URL	Logistic Regression, Random Forest, Naive Bayes, dan SVM
Hasil Penelitian ini menunjukkan bahwa deteksi phishing URL dapat ditingkatkan secara efisien melalui pendekatan machine learning berbasis seleksi fitur. Dari toal 130 fitur (87 fitur hasil ekstraksi URL asli dan 43 fitur tambahan), 10 fitur dipilih dengan menerapkan			

Mutual Information. Dengan hanya 10 fitur terpilih tersebut, kinerja tiap model adalah Naive Bayes akurasi 82,76% (sensitivitas 95,14%), Logistic Regression akurasi 87,62% (sensitivitas 88,02%), SVM akurasi 89,94% (sensitivitas 88,20%), dan Random Forest sebagai yang terbaik dengan akurasi 95,36% (sensitivitas 94,23%), sehingga menegaskan bahwa reduksi fitur dapat menekan kompleksitas komputasi tanpa mengorbankan performa, bahkan kompetitif dibanding studi terdahulu yang masih menggunakan fitur jauh lebih banyak (73–87 fitur).			
Single and Hybrid-Ensemble Learning-Based Phishing Website Detection: Examining Impacts of Varied Nature Datasets and Informative Feature Selection Technique (Adane dkk., 2023)	Pada penelitian ini digunakan tiga dataset dengan kategori fitur dan jumlah fitur yang berbeda: DS-1 memuat fitur dari kategori URL, web content/source code, domain, dan page rank dengan total 87 fitur, lalu setelah penerapan Univariate Feature Selection (UFS) digunakan 69 fitur; DS-2 juga mencakup kategori URL, web content/source code, domain, dan page rank dengan total 31 fitur, kemudian setelah UFS digunakan 27 fitur; sedangkan DS-3 hanya menggunakan kategori fitur URL dan web content/source code dengan total 48 fitur dan seluruhnya dipakai tanpa seleksi fitur.	DS-1 dari Mendeley (Hannousse & Yahiouche, 2021): 11.430 URL DS-2 dari Kaggle (oleh eswarchandt): 11.054 URL DS-3 (Chiew dkk., 2019): 10.000 URL	Random Forest, Catboost, Gradient Boosting, stacking (dari tiga model sebelumnya), dan majority hard vote (dari tiga model sebelumnya)
Hasil Penelitian ini menemukan bahwa pendekatan ensemble learning (single maupun hybrid/stacking dan majority vote) untuk deteksi phishing URL menunjukkan performa yang konsisten tinggi lintas dataset, dan performanya dapat makin efisien lewat seleksi fitur. Studi ini menguji RF, Gradient Boosting, dan CatBoost serta hybrid (stacking dan hard vote) pada 3 dataset berbeda. Setelah diterapkan (DS-1: 87 fitur/11.430 data; DS-2: 31 fitur/11.054 data; DS-3: 48 fitur/10.000 data), menerapkan Uni-variate Feature Selection (UFS) menggunakan ANOVA F-test untuk mengurangi dimensi pada DS-1 dan DS-2, hasilnya menunjukkan CatBoost paling unggul dan stabil dengan akurasi 97,9% (DS-1), 97,36% (DS-2), 98,59% (DS-3), sementara Random Forest menjadi yang paling cepat secara waktu komputasi di semua dataset; penerapan UFS juga terbukti menaikkan akurasi sekaligus menurunkan/menjaga waktu komputasi, sehingga relevan dijadikan pijakan bahwa kombinasi pemilihan fitur dan ensemble efektif untuk meningkatkan akurasi dan efisiensi deteksi phishing.			
Phishing URL *Detection: A*	URL length, domain length, subdomain length, path length, number of subdomains, number of digits in	Dataset ini terdiri 90.000 URL yang terdiri atas 30.000 Phishing	Logistic Regression, Light Gradient

Real-Case Scenario Through Login URLs (Sanchez-Paniagua dkk., 2022)	URL, number of digits in domain, number of digits in path, symbol frequency, number of words, minimum word length, maximum word length, average word length, standard deviation of word length, randomness score, contains “login”, “secure”, “signin”, “account”, “verify”, punycode detection, suspicious TLD presence, abnormal characters presence, URL entropy, digit-letter ratio, number of consecutive digits, number of consecutive letters, character diversity, repeated character count, special token presence, substring frequency indicators.	URLs, 30.000 Legitimate Homepage URLs, 30.000 Legitimate Login URLs. Dataset ini akan dibagi menjadi 2 subset yaitu PIU-60K (berisi Legitimate Homepage URLs dan Phishing URLs) dan PLU-60K (berisi Legitimate Login URLs dan Phishing URLs)	Boosting, XGBoost, AdaBoost, Random Forest, Support Vector Machines, k-Nearest Neighbours (KNN), Naive Bayes
Hasil: TF-IDF + Logistic Regression memberikan performa terbaik dengan akurasi 96.93% pada dataset homepage (PIU-60K) dan 96.50% pada dataset login (PLU-60K). Model Machine Learning berbasis handcrafted features seperti XGBoost, LightGBM, dan Random Forest hanya mencapai sekitar 94.4-94.7% pada PIU-60K dan menurun menjadi 92.9-93.2% pada PLU-60K karena struktur login URL mirip phishing. Sementara itu, model Deep Learning (CNN Kim dan CNN Zhang) menghasilkan akurasi 96.43% dan 95.22% pada PIU-60K, serta 96.00% dan 94.10% pada PLU-60K.			
Enhanced Phishing Website Detection Using Optimized Ensemble Stacking Models (Alamri dkk., 2025)	length_url, nb_dots, domain_age, iframe, tld_in_path, google_index, ratio_digits_host, ttl_hostname, qty_redirects, url_shortened, tls_ssl_certificate, domain_google_index.	Dataset 1 dari Mendeley berisikan 11.430 URL dengan 89 fitur, yang terdiri atas 5.715 phishing dan 5.715 legitimate. Dataset 2 dari Kaggle berisikan 11.481 URL dengan 89 fitur, yang terdiri atas 5.740 phishing dan 5.741 legitimate. Dataset 3 dari Mendeley berisikan 88.647 URL dengan 112 fitur, yang terdiri atas 30.648 phishing dan 57.999 legitimate. Dataset 4 dari Mendeley	Base Models: Random Forest, Gradient Boosting, XGBoost, CatBoost, LightGBM, Extra Trees, Support Vector Classifier, AdaBoost, Bagging. Ensemble: Standard Stacking + 4 Optimized Stacking Variants (Optimized Stacking-1, -2, -3, -4) dengan *meta-*

		berisikan 58.645 URL dengan 112 fitur, yang terdiri atas 30.651 phishing dan 27.994 legitimate.	*learner* CatBoost (setelah optimalisasi)
Hasil: Optimized Stacking 1 dan 2 mencapai akurasi 100% pada dua dataset balanced (Dataset 1 dan 2), sedangkan pada dataset besar dan imbalanced (Dataset 3 dan 4) memiliki nilai 99.71% untuk Dataset 3 dan 99.28% untuk Dataset 4. Hasil eksperimen juga menunjukkan bahwa base classifiers seperti XGBoost, CatBoost, dan Random Forest secara konsisten memiliki performa tinggi, namun kombinasi mereka melalui stacking dengan CatBoost sebagai meta-learner dapat memberikan peningkatan yang signifikan dalam akurasi, recall, dan F1-Score.			
An effective detection approach for phishing websites using URL and HTML features (Aljofey dkk., 2022)	Penelitian ini menggunakan total 15 fitur yang dikelompokkan ke dalam empat kategori utama, yaitu fitur berbasis URL, fitur konten tekstual, fitur informasi hyperlink, dan fitur informasi login form. Fitur berbasis URL mencakup character sequence vectors yang diproses pada level karakter. Fitur konten tekstual menggunakan TF-IDF character level yang diekstrak dari plaintext dan noisy part HTML. Fitur hyperlink mencakup script files, CSS files, image files, anchor files, null hyperlinks, internal/external hyperlinks, dan error hyperlinks.	Dataset yang digunakan berjumlah 60.252 halaman web dengan distribusi 27.280 URL phishing dan 32.972 URL benign. Data phishing dikumpulkan dari PhishTank (Agustus 2016 - April 2020) dan data benign dari Stuff Gate (Februari 2020). Dataset mencakup URL lengkap beserta kode sumber HTML, dibagi dengan rasio 80:20 untuk training dan testing.	Algoritma yang Digunakan *eXtreme Gradient Boosting (XGBoost). Performa kemudian dibandingkan dengan algoritma lain seperti Random Forest, Logistic Regression, Naïve Bayes, Ensemble, Deep Neural Network (DNN), CNN, dan LSTM.*
Hasil: Hasil penelitian menunjukkan bahwa model XGBoost dengan kombinasi seluruh fitur mampu mencapai akurasi sebesar 96.76%, dengan nilai precision 98.28%, recall 94.56%, F-Score 96.38%, dan False Positive Rate (FPR) hanya 1.39%. Pada benchmark dataset, model mencapai akurasi 98.48% dengan FPR 2.09%. Performa ini terbukti lebih unggul dibandingkan pendekatan sebelumnya seperti Le dkk. yang mencapai 93.91% dan Aljofey dkk. yang mencapai 95.94%. Hal ini membuktikan bahwa pendekatan hybrid yang menggabungkan fitur URL, hyperlink, dan konten tekstual lebih efektif dalam mendeteksi website phishing dengan waktu deteksi real-time 2-3 detik.			

Comparative Study of Machine Learning Algorithms for Phishing Website Detection (Omari, 2023)	Penelitian ini terdiri atas 30 fitur yang bersumber dari dataset UCI. Variabel yang dianalisis mencakup karakteristik alamat IP dan panjang URL, fitur abnormalitas, elemen HTML dan JavaScript seperti *pop-up window* dan *right-click disable*, serta informasi domain seperti umur domain, catatan DNS, dan *page rank*.	Data diambil dari repositori UCI *Machine Learning* dengan total 11.055 sampel URL yang terdiri dari situs *legitimate* dan *phishing*.	Algoritma yang Digunakan *Gradient Boosting*, *Random Forest*, *Decision Tree*, *K-Nearest Neighbors* (KNN), *Support Vector Machine* (SVM), *Logistic Regression*, dan *Naive Bayes*.
Hasil: Hasil Penelitian menunjukkan bahwa algoritma berbasis *ensemble* menghasilkan performa terbaik. *Gradient Boosting* mencatat akurasi tertinggi sebesar 97,2%, disusul oleh *Random Forest* dengan 97,1%. Sementara itu, model SVM mendapatkan akurasi 93,9%, sedangkan *Naive Bayes* memiliki performa terendah di angka 60,1%. Kesimpulannya, metode *ensemble* terbukti lebih stabil dan akurat dibandingkan model tunggal lainnya dalam mendeteksi *phishing* pada dataset ini.			
Web Phishing Detection and Awareness Utilizing Hybrid Machine Learning Algorithms (Alheyasat, 2025)	Penelitian ini menggunakan 87 fitur awal yang berasal dari tiga kategori utama: fitur sintaks URL (56 fitur), fitur konten halaman web (24 fitur), dan fitur eksternal hasil query layanan pihak ketiga (7 fitur). Variabel kemudian disaring menggunakan correlation-based filtering, dengan beberapa ambang korelasi (0,5, 0,3, 0,1), hingga menghasilkan subset 34 fitur terpilih dan versi lain dengan 5 fitur berkolerasi tinggi. Selain itu, penelitian menambahkan satu fitur baru berupa prediksi awal dari model Random Forest (akurasi 91%) sebagai fitur tambahan untuk meningkatkan kinerja model.	Dataset penelitian terdiri dari 11.430 URL, yang seimbang antara 50% phishing dan 50% legitimate	K-Means untuk mengelompokkan URL menjadi phishing dan legitimate (0/1), Random Forest, XGBoost, Decision Tree, Support Vector Machine (SVM). Keempat model digabung menjadi hard voting ensemble.
Hasil: Hasil ensemble menunjukkan peningkatan yang jauh lebih besar ketika diterapkan pada fitur yang sudah disaring dengan ambang korelasi 0,1. Model hybrid mencapai akurasi 99.72%, precision 99.81%, recall 99.57%, dan F1-score 99.70%, menunjukkan kemampuan mendeteksi phishing dengan tingkat kesalahan yang sangat rendah. Performa ini juga menandai peningkatan signifikan			

<table>
<tr><td colspan="4">meskipun jumlah fitur dikurangi hampir 60% dari total fitur awal (dari 87 ke 34 fitur).</td></tr>
<tr><td>Comparative study of classification algorithms for phishing URL detection (Sari & Wijaya, 2024)</td><td>Penelitian ini menggunakan 23 fitur atau variabel yaitu url_length, hostname_length, count-www, count@, count_dir, count_embed_domain, short_url, count-https, count-http, count%, count?, count-, count=, url_length, hostname_length, sus_url, fd_length, tld_length, count-digits, abnormal_url, use_of_ip_address, dan google_index.</td><td>Dataset diambil dari Kaggle (Malicious URLs Dataset, n.d.) yang berisi 651,191 URLs dengan 4 klasifikasi.</td><td>Logistic Regression</td></tr>
<tr><td colspan="4">Hasil:
Penelitian ini menerapkan algoritma Logistic Regression untuk mendeteksi situs web berbahaya dengan mengoptimalkan tahapan praproses data dan evaluasi model. Hasil menunjukkan akurasi uji sebesar 92,6%. Evaluasi lanjutan menggunakan precision, recall, dan F1-score menunjukkan kinerja seimbang pada kedua kelas, dengan macro average sekitar 92.7%. Selain itu, pengujian menggunakan 5-fold cross-validation memperlihatkan kurva akurasi yang stabil, menegaskan bahwa model memiliki generalisasi yang baik. Temuan ini membuktikan bahwa Logistic Regression yang dikombinasikan dengan praproses data yang tepat dapat menjadi metode yang efektif untuk deteksi situs web berbahaya.</td></tr>
<tr><td>Feature selection to enhance phishing website detection based on machine learning (Rani & Foozy, 2023)</td><td>Fitur dipilih menggunakan bantuan IG dan TreeSHAP dengan pemilihan 10, 15, dan 20 peringkat teratas fitur yang dipilih oleh kedua teknik tersebut untuk kedua dataset.</td><td>Penelitian ini menggunakan dua dataset. Dataset 1 bersumber dari ISCX-URL-2016. Dataset 2 bersumber dari penelitian yang dilakukan oleh Hannousse dan Yahiouche pada tahun 2020.</td><td>Naive Bayes, Random Forest, dan XGBoost.</td></tr>
<tr><td colspan="4">Hasil:
Pada dataset satu, semua model mencapai lebih dari 90% untuk akurasi, precision, dan recall. Algoritma XGBoost + TreeSHAP (Top 15 fitur) menghasilkan performa terbaik dengan akurasi 98,561%, precision 0,9886, dan recall 0,9823. Untuk dataset kedua, kombinasi terbaik adalah Random Forest + TreeSHAP (20 fitur) dengan akurasi 90,247%, precision 0,8961, dan recall 0,9191. Teknik TreeSHAP terbukti lebih stabil daripada IG dalam memilih fitur paling relevan. Dengan TreeSHAP, jumlah fitur sedikit (10–20) sudah cukup untuk mempertahankan akurasi sangat tinggi, menghindari kebutuhan memakai seluruh fitur.</td></tr>
</table>

Phishing website prediction using base and ensemble classifier techniques with cross-validation (Awasthi & Goel, 2022)	Kedua dataset berisikan 30 fitur URL, yaitu *having_ip, url_length, shortining_service, having_At_Symbol, double_slash_redirect, prefix_suffix, having_sub_domain, sslfinal_state, Domain_registration_length, favicon, port, https_token, Request_url, url_of_anchor, links_in_tags, SFH, submitting_to_email, abnormal_url, redirect, on_mouseover, right_click, popUpWindow, iframe, age_of_domain, dns_record, web_traffic, page_rank, google_index, Link_pointing_to_page,* dan *statistical_report.*	Penelitian ini menggunanan 3 dataset di mana dataset 1 berasal dari UCI Machine Learning Repository: Phishing Websites Data Set berisikan 2.456 URLs, dataset 2 berasal dari Kaggle: Phishing website dataset berisikan 11.055 URLs, dan dataset 3 merupakan gabungan antara dataset 1 dan dataset 2 yang berisikan 13.511 URLs..	Logistic Regression, Decision Tree, Support Vector Machine, K-Nearest Neighbour, Gaussian Naive Bayes, Linear Discriminant Analysis, Bagged Decision Tree, Gradient Boosting, Voting Ensemble, AdaBoost, Extra Trees, XG Boost.
Hasil: Di kategori *base classifier,* Decision Tree merupakan model terbaik dengan akurasi 95,87%. Sedangkan pada model *ensemble*, model Extra Trees dan XGBoost unggul pada dataset 1 (UCI) dengan akurasi sama yaitu sebesar 99,18%. Untuk dataset kedua (Kaggle), Extra Trees kembali unggul dengan akurasi 98,73%. Ketika ukuran dataset diperbesar dengan menggunakan dataset ketiga yaitu dataset gabungan, model tanpa *cross validation* menjadi menurun. Namun, dengan *cross-validation*, model Extra Trees menjadi model dengan akurasi terbaik meskipun dataset besar, dengan akurasi 98,59%. Extra Trees adalah model paling unggul dan konsisten dalam semua eksperimen, khususnya ketika *cross-validation* diterapkan. XGBoost mengikuti sangat dekat sebagai *runner-up.*			

Metode Penelitian

Untuk mencapai tujuan deteksi phishing URL yang akurat, langkah pertama dalam metode penelitian ini adalah penentuan dan karakterisasi data yang akan digunakan.

1. Bahan

Penelitian ini menggunakan dataset phishing dari Mendeley Data yang berjumlah 11.430 entri dengan 87 variabel (fitur) yang merepresentasikan berbagai karakteristik situs web, meliputi struktur URL, konten halaman, atribut domain, serta reputasi jaringan (Hannousse & Yahiouche, 2021). Dataset ini termasuk dalam kategori *high-dimensional dataset* karena mencakup fitur bertipe numerik (*int64*) dan rasio (*float64*) dengan total 87 kolom dan tipe data yang beragam. Sejumlah penelitian terdahulu menunjukkan bahwa kombinasi fitur dari berbagai dimensi seperti struktur URL, konten HTML, dan atribut domain yang dapat secara signifikan meningkatkan kemampuan model *Machine Learning* dalam mendeteksi situs phishing yang kompleks (Ghosh & Singh, 2023; Al-Mekhlafi et al., 2023; Ramesh & Reddy, 2022).

Meskipun demikian, penelitian ini tidak menggunakan seluruh variabel yang terdapat dalam dataset. Proses pemilihan fitur (*feature selection*) dilakukan berdasarkan penelitian Bari dkk. (2025). Proses detail terdapat pada tahap *pre-processing*. Hasilnya hanya enam variabel utama yang dinilai paling berpengaruh terhadap performa model yang digunakan. Keenam variabel tersebut meliputi domain_age, web_traffic, google_index, dan page_rank yang termasuk dalam kategori fitur domain dan reputasi, serta ratio_extHyperlinks dan ratio_intHyperlinks yang termasuk dalam kategori fitur konten HTML dan interaktivitas. Pengelompokan dan penggunaan variabel ini ditampilkan secara ringkas pada Tabel 2, yang menunjukkan hubungan antara kategori fitur dan variabel terpilih dalam penelitian ini.

Tabel 2. Klasifikasi Variabel Terpilih Berdasarkan kategori Fitur

No.	Nama Variabel	Kategori Fitur	Deskripsi
1.	domain_age	Domain dan Reputasi	Menunjukkan umur domain sejak pertama kali didaftarkan.
2.	web_traffic	Domain dan Reputasi	Mengukur tingkat kunjungan situs web berdasarkan data lalu lintas pengguna.
3.	google_index	Domain dan Reputasi	Menunjukkan apakah situs terindeks oleh mesin pencari Google
4.	page_rank	Domain dan Reputasi	Menilai peringkat situs dalam indeks mesin pencari berdasarkan popularitas dan jumlah tautan masuk.
5.	ratio_extHyperlinks	Konten HTML dan Interaktivitas	Rasio jumlah tautan eksternal terhadap total tautan dalam halaman.
6.	ratio_intHyperlinks	Konten HTML dan Interaktivitas	Rasio jumlah tautan internal terhadap total tautan dalam halaman.

1.1 Fitur Domain dan Reputasi

Fitur domain dan reputasi berfungsi untuk menilai tingkat kredibilitas dan legitimasi suatu situs web berdasarkan umur domain, status indeksasi, serta popularitasnya di mesin pencari (Hannousse & Yahiouche, 2021). Aspek ini penting karena situs phishing umumnya menggunakan domain baru yang didaftarkan dalam jangka waktu singkat dan belum memiliki reputasi kuat di internet (Al-Mekhlafi dkk., 2022). Variabel seperti domain_age, web_traffic, google_index, dan page_rank menjadi indikator penting untuk menilai sejauh mana situs tersebut dikenal dan diakui secara daring (Alzboon dkk., 2025).

Menurut Al-Mekhlafi dkk. (2022) dan Alzboon dkk. (2025), domain yang baru terdaftar dengan *page rank* rendah dan tidak terindeks di mesin pencari memiliki kecenderungan tinggi untuk digunakan dalam serangan phishing karena lebih mudah dibuat dan sulit dilacak secara historis. Al Saedi dan Flayh (2023) menekankan bahwa integrasi informasi registrasi domain dengan reputasi daring dapat meningkatkan akurasi deteksi phishing hingga lebih dari 10% dibandingkan model yang hanya mengandalkan fitur URL. Selain itu, Hannousse dan Yahiouche (2021) menunjukkan bahwa variabel berbasis reputasi domain memiliki peran penting dalam membedakan situs sah dari situs phishing karena sering kali berhubungan langsung dengan kredibilitas dan visibilitas situs di mesin pencari seperti Google.

1.2 Fitur Konten HTML dan Interaktivitas

Fitur konten HTML dan interaktivitas merepresentasikan aspek perilaku dan struktur halaman web yang dapat diamati melalui komponen internal situs, seperti jumlah dan rasio tautan internal (ratio_intHyperlinks) serta tautan eksternal (ratio_extHyperlinks) (Islam dkk., 2023). Rasio tautan ini menggambarkan bagaimana halaman web berinteraksi dengan domain lain dan dapat digunakan untuk membedakan situs *phishing* dari situs valid(Barik dkk., 2025).

Menurut Islam dkk. (2023) dan Barik dkk. (2025), situs phishing umumnya memiliki proporsi tautan eksternal yang tinggi karena halaman-halaman tersebut sering dirancang untuk mengarahkan pengguna ke domain lain dengan tujuan mencuri data sensitif. Sebaliknya, situs valid cenderung memiliki lebih banyak tautan internal yang menghubungkan antarhalaman dalam domain yang sama, yang mencerminkan struktur navigasi yang konsisten dan autentik (Alzubi dkk., 2025). Selain itu, Hannousse dan Yahiouche (2021) menyebutkan bahwa analisis terhadap pola *hyperlink* dapat memperkuat kemampuan model dalam mendeteksi perilaku mencurigakan yang tidak dapat diidentifikasi hanya melalui analisis URL.

2. Metodologi

Alur kerja pada penelitian ini dilakukan melalui beberapa tahapan. Tahapan-tahapan ini dijelaskan pada Gambar 1.

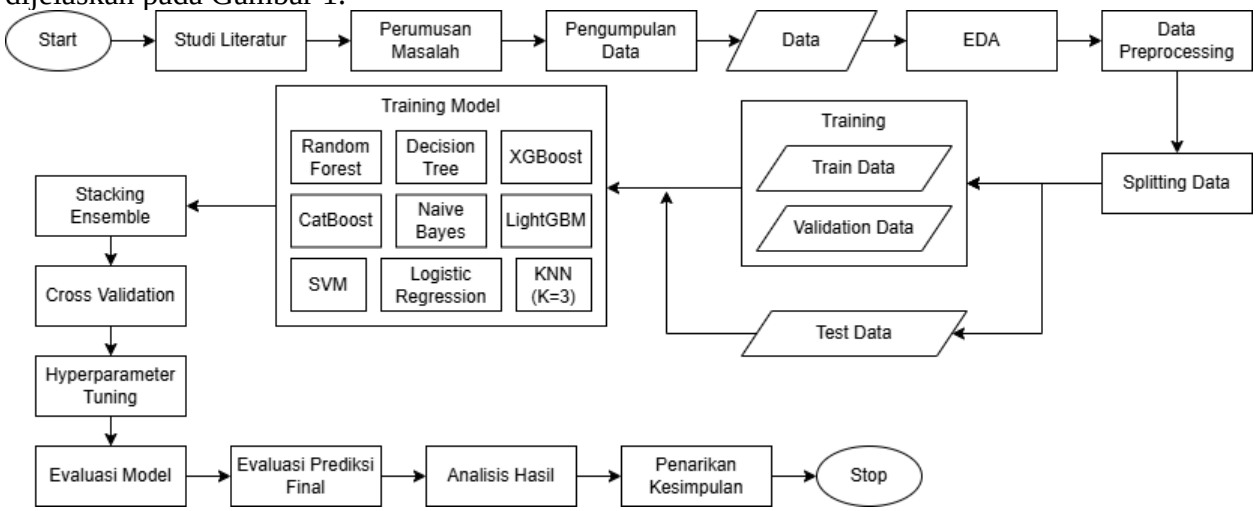

Gambar 1. Alur Pengolahan Data

Proses penelitian ini diawali dengan tahap studi literatur untuk memahami konsep dasar phising berbasis URL, teknik ekstraksi fitur, serta metode *machine learning* yang relevan untuk deteksi *phishing*. Seluruh data yang terkumpul diperiksa pada tahap awal untuk memastikan struktur dan kelengkapannya, termasuk proses ekstraksi domain dari URL dan penandaan situs yang terbukti aman berdasarkan allow list tersebut. Data yang telah tersusun kemudian dianalisis pada tahap *Exploratory Data Analysis* (EDA) untuk memahami karakteristik fitur, distribusi nilai,

serta potensi anomali atau inkonsistensi pada data (Alzubi dkk, 2025). Tahap selanjutnya adalah preprocessing dan seleksi fitur untuk memastikan bahwa model *machine learning* dapat bekerja secara optimal. Proses ini mencakup penghapusan fitur tidak relevan seperti URL mentah dan domain menggunakan *allowlist* yang didapatkan dari Alexa Top Website. Selanjutkan dilakukan penghapusan fitur variabel X seperti yang dilakukan Bari dkk. (2025). Penelitian ini menggunakan seleksi variabel yang konstan dan duplikat, eliminasi fitur *quasi-constant*, dan penyaringan fitur yang memiliki korelasi tinggi untuk mengurangi risiko *multicolinearity*.

Setelah itu dilakukan seleksi fitur berbasis *Mutual Information* dengan mempertahankan fitur-fitur yang memiliki nilai MI di atas ambang tertentu sesuai penelitian Prakongsin & Kanjanasurat (2025), sehingga hanya informasi paling relevan yang digunakan. Dari 87 fitur yang digunakan, hanya 6 fitur yang akan digunakan dalam pemodelan *machine learning*, yaitu *domain_age, web_traffic, google_index, page_rank, ratioextHyperlinks,* dan *ratio_intHyperlinks.* Seluruh fitur terpilih kemudian dinormalisasi menggunakan Min-Max Scaler agar berada pada rentang nilai yang seragam.

Setelah preprocessing selesai, data dibagi menjadi tiga bagian yaitu 70% data training, 15% data validasi, dan 15% data testing menggunakan teknik *stratified splitting* agar proporsi kelas tetap seimbang. Data training digunakan untuk melatih berbagai model *machine learning* seperti Random Forest, Decision Tree, XGBoost, CatBoost, LightGBM, Logistic Regression, SVM, Naive Bayes, dan K-Nearest Neighbors. Data validasi digunakan untuk mengevaluasi performa awal model dan membandingkan kemampuan antar algoritma. Selain model individu, penelitian ini juga mengembangkan *Stacking Ensemble* yang menggabungkan tiga algoritma terbaik untuk meningkatkan performa prediksi.

Tahap evaluasi model dilakukan menggunakan berbagai metrik seperti *precision*, *recall*, dan *F1-score* (Yu dkk., 2023). Namun, penelitian ini menekankan metrik recall karena tujuan utama adalah meminimalkan risiko *false negative*, yaitu kondisi ketika URL *phishing* salah diklasifikasikan sebagai *legitimate*. Kesalahan jenis ini berpotensi membahayakan pengguna, sehingga model dengan recall tinggi dianggap lebih aman meskipun harus menerima kompromi kecil pada metrik lain seperti precision. Setelah model terbaik ditentukan melalui evaluasi recall, dilakukan *Cross-Validation* 10-fold untuk memastikan stabilitas performa model. Jumlah *fold* ini juga digunakan dalam penelitian Alsharaiah dkk. (2023) dan Wahyudi (2022).

Langkah berikutnya adalah melakukan *hyperparameter tuning* menggunakan RandomizedSearchCV untuk mengoptimalkan model LightGBM yang menjadi kandidat utama, sebagaimana yang dilakukan Khaldi dkk. (2025). Pendekatan ini dipilih karena random search mampu menemukan kombinasi parameter optimal dengan biaya komputasi yang lebih rendah dibandingkan pencarian menyeluruh (*grid search*), sambil tetap mempertahankan kualitas performa model. Model terbaik hasil *tuning* kemudian dianalisis lebih lanjut melalui analisis kesalahan.

Setelah alur metodologi dirumuskan, penelitian ini juga memetakan seluruh variabel yang digunakan dalam proses pemodelan. Fitur-fitur tersebut dikelompokkan ke dalam lima kategori utama berdasarkan karakteristik teknis URL dan atribut pendukung lainnya. Rincian lengkap mengenai fitur yang digunakan disajikan pada Tabel 2.

Result

1. Exploratory Data Analysis

Eksplorasi data dilakukan melalui visualisasi untuk memahami distribusi dan hubungan antar variabel. Selain itu, analisis statistik deskriptif akan memberikan gambaran lebih lanjut mengenai karakteristik data secara keseluruhan.

Tabel 3. Statistika Deskriptif

Fitur	**Mean**	**Std**	**Min**	**Median**	**Max**
domain_age	4062,54	3107,78	-12	3993	12874
web_traffic	856756,6	1995606	0	1651	10767990
google_index	0,53	0,49	0	1	1
page_rank	3,19	2,54	0	3	10
ratio_intHyperlinks	0,6	0,38	0	0,74	1
ratio_extHyperlinks	0,28	0,32	0	0,13	1

Statistika deskriptif menunjukkan bahwa usia domain (domain_age) memiliki rata-rata sekitar 11 tahun dengan variasi yang besar, menandakan adanya kombinasi domain yang sangat baru hingga sangat tua; kondisi ini penting karena domain phishing umumnya berusia pendek. Web traffic juga memiliki sebaran yang sangat lebar dan cenderung right-skewed, di mana sebagian besar domain memiliki kunjungan yang sangat rendah, konsisten dengan karakteristik situs phishing yang biasanya tidak memiliki trafik organik. Fitur google_index menunjukkan bahwa hanya sekitar separuh domain yang terindeks oleh Google, menguatkan asumsi bahwa banyak situs phishing tidak terdaftar dalam mesin pencari. Page rank memiliki nilai rata-rata rendah hingga menengah, yang mengindikasikan bahwa sebagian besar domain tidak memiliki otoritas tinggi, sementara situs phishing biasanya memiliki page rank rendah. Pada struktur hyperlink, proporsi internal link cenderung lebih tinggi daripada external link, mencerminkan pola umum halaman web yang stabil, namun rasio external link tetap menunjukkan variasi yang besar yang dapat mencerminkan aktivitas mencurigakan seperti pengalihan pengguna ke situs luar. Secara keseluruhan, pola distribusi pada fitur-fitur ini memberikan indikasi kuat mengenai perbedaan karakteristik antara domain legitimate dan domain phishing, sehingga relevan digunakan dalam proses klasifikasi URL *phishing*.

Visualisasi variabel target Status (Gambar 2) menunjukkan frekuensi kemunculan URL yang *legitimate* dan URL *phishing*. Distribusi data mengindikasikan data yang cukup seimbang, dengan jumlah URL *legitimate* (sekitar 6.100) sedikit lebih banyak dibandingkan URL *phishing* (sekitar 5.200). Data yang *balanced* atau seimbang merupakan kondisi yang baik untuk pemodelan *machine learnin*g karena meminimalkan risiko bias model terhadap kelas mayoritas. Histogram *Domain Age* (Gambar 3) menunjukkan distribusi condong ke kanan (*right-skewed*). Hal ini menunjukkan bahwa sebagian besar URL dalam dataset memiliki usia yang muda (mendekati 0 hari). Usia yang muda sangat sesuai dengan karakteristik situs *phishing* yang bersifat sementara dan cepat hilang. Meskipun demikian, visualisasi juga menunjukkan adanya situs yang memiliki usia lebih tua, terutama di rentang 4.000 hingga 8.000 hari yang mewakili sebagian besar URL *legitimate*. Pola distribusi ini mendukung variabel *Domain Age* sebagai variabel yang relevan untuk membedakan antara domain phishing dan domain *legitimate* dalam proses klasifikasi.

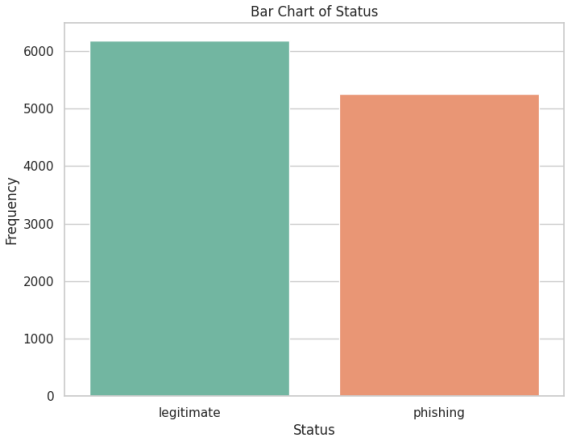

Gambar 2. Bar Chart untuk Variabel Status

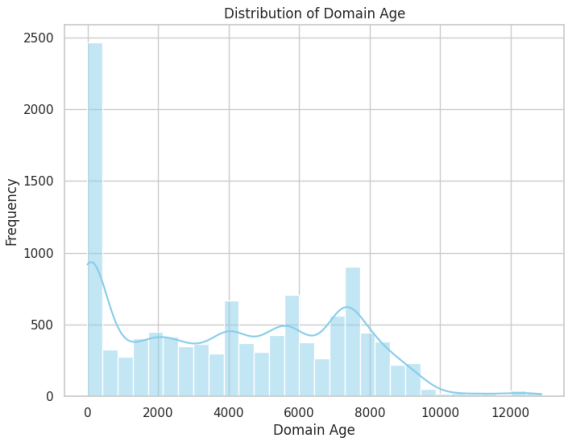

Gambar 3. Histogram Distribusi Variabel *Domain Age*

Variabel Google Index menandakan domain yang diberikan index oleh mesin pencari Google. Variabel Google Index sangat penting dalam konteks deteksi *phishing* karena mengindikasikan apakah suatu halaman atau domain telah didaftar dan diakui oleh mesin pencari Google. Nilai 1.0 menunjukkan bahwa situs memiliki index dari Google. Hal tersebut cenderung menunjukkan bahwa situs *legitimate* atau setidaknya telah beroperasi cukup lama untuk diakui Google. Sedangkan nilai 0.0 menunjukkan bahwa situs tidak terindeks dan cenderung mencurigakan. Dari visualisasi yang ditunjukkan pada Gambar 4, ditunjukkan bahwa frekuensi situs yang terindeks (1.0) dan yang tidak terindeks (0.0) lumayan setara atau *balanced*. Situs yang terindeks sejumlah sekitar 6.100 dan sedikit lebih banyak dibandingkan situs yang tidak terindeks yang berjumlah sekitar 5.300.

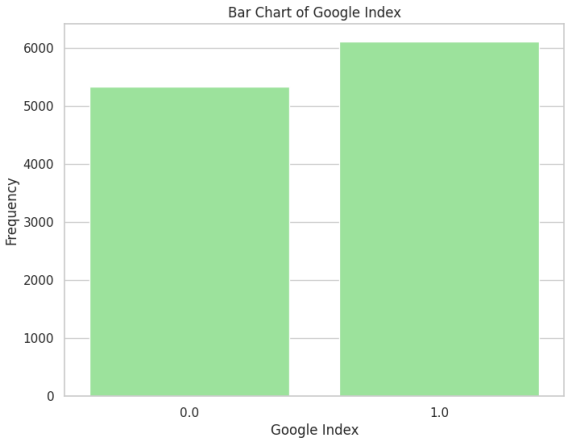

Gambar 4. Bar Chart Variabel Google Index

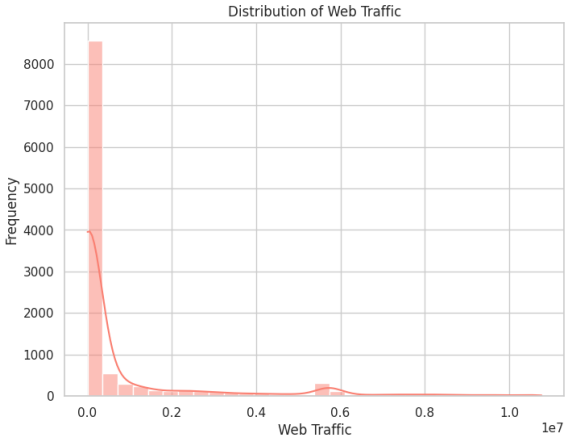

Gambar 5. Histogram Distribusi Variabel *Web Traffic*

Gambar 5 menunjukkan histogram untuk variabel *web traffic*. Variabel tersebut menunjukkan jumlah kunjungan dan aktivitas yang terjadi di sebuah *website* atau situs. Semakin tinggi nilainya, maka semakin banyak pengunjung yang datang ke situs tersebut. Histogram distribusi *web traffic* (Gambar 5) menunjukkan pola distribusi yang condong ke kanan (*right skewed*). Frekuensi tertinggi variabel ini terdapat pada nilai 0 yang menunjukkan bahwa sebagian besar URL dalam dataset memiliki *web traffic* yang sangat kecil. Hal ini cocok dengan karakteristik situs *phishing* yang berjalan secara tersembunyi sehingga jumlah kunjungannya sedikit. Meskipun begitu, terdapat beberapa situs yang memiliki nilai *web traffic* yang tinggi.

Dengan nilai yang tinggi, maka tinggi juga kemungkinan bahwa situs tersebut merupakan situs *legitimate*.

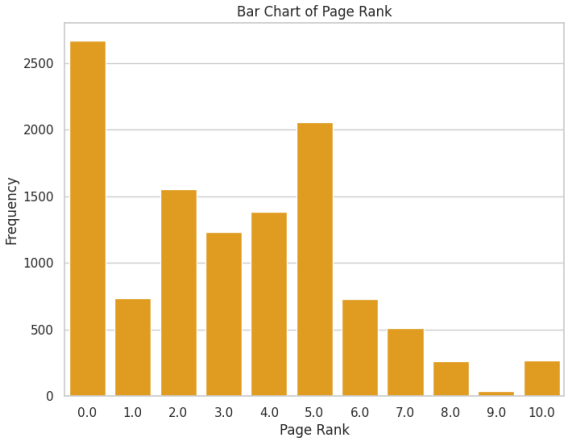

Gambar 6. Bar Chart Variabel *Page Rank*

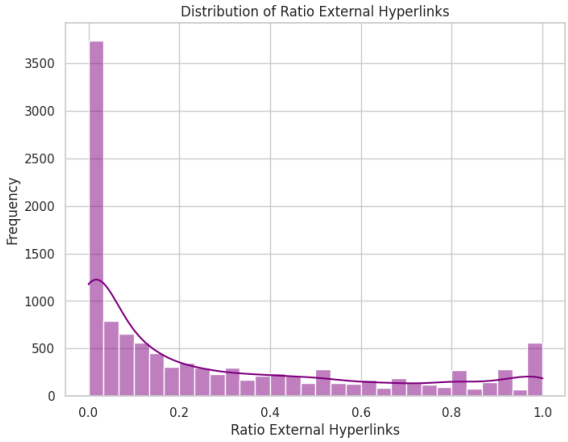

Gambar 7. Histogram Distribusi Variabel *Ratio External Hyperlinks*

Visualisasi yang terlihat pada Gambar 6. menunjukkan distribusi nilai *Page Rank* dari URL dalam dataset. Frekuensi tertinggi berada pada nilai 0.0 dengan sekitar 2.600 URL, diikuti nilai 5.0 dengan sekitar 2.050 URL. Hal ini menunjukkan bahwa sebagian besar URL memiliki *Page Rank* sangat rendah, yang merupakan ciri khas situs *phishing* yang baru dibuat dan belum memiliki reputasi, sedangkan URL dengan *Page Rank* lebih tinggi kemungkinan merupakan situs *legitimate* yang sudah memiliki kredibilitas. Sementara itu, visualisasi yang terlihat pada Gambar 7. menunjukkan distribusi rasio *external hyperlinks* yang mengukur proporsi link keluar dari domain ke domain lain. Histogram menunjukkan distribusi yang cenderung ke kanan (*right-skewed*) dengan frekuensi tertinggi pada nilai mendekati (sekitar 3.700 URL), yang berarti mayoritas URL memiliki rasio *external hyperlinks* sangat rendah. Hal ini dapat menunjukkan situs *phishing* yang dibuat sederhana dengan konten minimal atau situs *legitimate* yang lebih fokus pada konten internal.

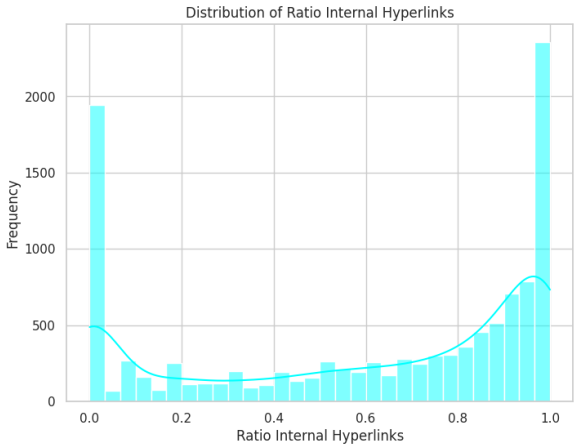

Gambar 8. Histogram Distribusi Variabel *Ratio Internal Hyperlinks*

Distribusi rasio internal hyperlinks memperlihatkan pola yang sangat menonjol pada nilai nol dan satu. Banyak halaman memiliki hampir tidak ada internal link, sementara banyak juga yang seluruh hyperlinknya bersifat internal. Ini mencerminkan dua karakter halaman yang berbeda: beberapa halaman tampak minim navigasi internal, sering ditemukan pada situs phishing yang hanya berupa halaman sederhana, sedangkan halaman lain menunjukkan struktur internal

yang kuat seperti pada situs legitimate. Nilai di tengah cenderung lebih jarang muncul, sehingga proporsi internal link jarang berada pada tingkat moderat.

2. Hasil Percobaan

Pada tahap awal preprocessing, penelitian ini menambahkan mekanisme *allowlist* domain untuk menyaring URL yang berasal dari sumber tepercaya. Langkah ini bertujuan untuk mengurangi *noise* pada data serta menekan kemungkinan kesalahan klasifikasi pada domain yang telah diketahui aman. Setelah proses penyaringan awal tersebut, dilakukan tahapan seleksi fitur mengikuti pendekatan yang diusulkan oleh Bari dkk. (2025).

Proses seleksi fitur diawali dengan penghapusan variabel yang bersifat konstan dan duplikat, diikuti dengan eliminasi fitur *quasi-constant*, sehingga jumlah fitur berkurang dari 87 menjadi 66 fitur. Selanjutnya, dilakukan penyaringan fitur dengan korelasi tinggi untuk meminimalkan risiko multikolinearitas antarvariabel, yang menghasilkan 64 fitur tersisa. Untuk memperoleh fitur yang paling relevan terhadap target klasifikasi *phishing*, diterapkan seleksi fitur berbasis *Mutual Information* (MI) dengan mempertahankan fitur yang memiliki nilai MI di atas ambang 0,22. Hasil dari tahapan ini menunjukkan bahwa hanya enam fitur yang memiliki kontribusi informasi paling signifikan terhadap deteksi *phishing*, yaitu *domain_age, web_traffic, google_index, page_rank, ratioextHyperlinks, dan ratio_intHyperlinks*. Dengan demikian, proses *pre-processing* dan seleksi fitur berhasil mereduksi kompleksitas data secara signifikan tanpa mengorbankan informasi penting yang dibutuhkan model.

Perlu dicatat bahwa fitur *google_index* merepresentasikan kondisi reputasi URL pada saat pengumpulan data tahun 2021. Oleh karena itu, fitur ini bersifat temporal dan dapat mengalami perubahan seiring waktu. Meskipun demikian, dalam konteks dataset yang digunakan, *google_index* terbukti efektif dalam membedakan URL *phishing* dan *legitimate*. Namun, ketergantungan terhadap fitur ini berpotensi memengaruhi generalisasi model apabila diterapkan pada data lintas waktu tanpa proses pembaruan model.

Setelah seleksi fitur, seluruh fitur numerik dinormalisasi menggunakan metode *Min-Max Normalization* untuk memastikan setiap fitur berada pada skala yang seragam. Normalisasi ini penting terutama bagi model berbasis jarak dan optimasi gradien agar proses pembelajaran berjalan lebih stabil dan efisien. Dataset kemudian dibagi menjadi tiga bagian, yaitu 70% data latih, 15% data validasi, dan 15% data uji, guna memastikan evaluasi model yang adil serta menghindari *overfitting* selama proses pelatihan dan penyetelan model.

Pada studi ini, *recall* dipilih sebagai metrik evaluasi utama karena dalam konteks deteksi *phishing*, kesalahan dalam melewatkan URL berbahaya (*false negative*) memiliki risiko yang jauh lebih besar dibandingkan kesalahan mengklasifikasikan URL aman sebagai *phishing (false positive*). Untuk memperoleh gambaran performa yang komprehensif, penelitian ini membandingkan sembilan algoritma *machine learning* dalam mengklasifikasikan URL *phishing*. Nilai *precision, recall,* dan *F1-score* yang dilaporkan difokuskan pada kelas 1 (*phishing*) dan disajikan pada Tabel 4.

Setiap model memiliki karakteristik, kemampuan generalisasi, serta kompleksitas yang berbeda sehingga memberikan gambaran komprehensif mengenai performa berbagai pendekatan klasifikasi. Algoritma pertama yang digunakan adalah LightGBM, model berbasis *gradient boosting* yang dikenal memiliki kecepatan tinggi, kemampuan menangani dataset besar, serta akurasi yang tinggi. Selanjutnya, XGBoost dan CatBoost termasuk dalam keluarga boosting yang terkenal efektif menangkap pola kompleks dan mengurangi *overfitting*. Random Forest digunakan sebagai contoh model berbasis *bagging* yang mampu mengurangi varians melalui kombinasi banyak *decision tree*. Model berbasis jarak seperti K-Nearest Neighbors (KNN) juga diuji karena

sederhana namun efektif pada pola tertentu. Selain itu, model yang lebih klasik seperti Decision Tree, Logistic Regression, Support Vector Machine (SVM), dan Naive Bayes juga digunakan untuk memberikan *baseline* kuat dan memastikan perbandingan yang objektif antara algoritma modern dan model-model konvensional yang umum digunakan dalam klasifikasi biner.

Tabel 4. Perbandingan Model

Nomor	**Metode**	**Precision**	**Recall**	**F1-Score**
1	LightGBM	0,945293	0,942893	0,944091
2	XGBoost	0,944801	0,93401	0,939375
3	CatBoost	0,942159	0,930203	0,936143
4	Random Forest	0,944516	0,928934	0,93666
5	KNN	0,910692	0,918782	0,914719
6	Decision Tree	0,902378	0,914975	0,908633
7	Logistic Regression	0,886534	0,902284	0,89434
8	SVM	0,895698	0,871827	0,883601
9	Naive Bayes	0,883378	0,836294	0,85919

Hasil evaluasi kesembilan model tersebut disajikan pada Tabel 4, yang menunjukkan nilai precision, recall, dan F1-score untuk kelas 1 (*phishing*). Dari hasil tersebut terlihat bahwa LightGBM, XGBoost, dan CatBoost menempati tiga posisi teratas berdasarkan nilai *recall*, sehingga ketiganya dinilai paling efektif untuk meminimalkan kesalahan pendeteksian URL berbahaya. Model berbasis *boosting* secara konsisten memberikan performa yang lebih tinggi dibandingkan model lainnya, terutama dalam hal sensitivitas terhadap kelas positif, yang merupakan prioritas utama dalam konteks deteksi *phishing.*

Oleh karena itu, dikembangkanlah sebuah model *stacking ensemble* dengan memanfaatkan ketiga algoritma tersebut, sebagaimana pendekatan yang digunakan dalam penelitian Adane, dkk. (2023), Bari, dkk. (2025), dan Alamri, dkk. (2025). Pada tahap ini, ketiga algoritma tersebut digunakan sebagai *base learners*, sementara algoritma Logistic Regression dipilih sebagai *meta learner*. Algoritma Logistic Regression dinilai cocok karena model ini sederhana, memiliki generalisasi yang baik, serta mampu menggabungkan output probabilitas dari base models secara efektif.

Skema kerja *stacking ensemble* adalah model XGBoost, LightGBM, dan CatBoost masing-masing dilatih pada data *training* menggunakan *5-fold cross-validation.* Setiap model menghasilkan prediksi yang kemudian menjadi input bagi *meta learner*. Kemudian, *meta learner* (Logistic Regression) mempelajari pola kombinasi tersebut untuk menghasilkan prediksi akhir dengan bias lebih rendah dan stabilitas lebih tinggi. Dengan strategi ini, model *stacking* mampu memanfaatkan keunggulan dari masing-masing algoritma, seperti algoritma LightGBM yang unggul dalam kecepatan dan efisiensi pada dataset besar, algoritma XGBoost memiliki mekanisme regularisasi kuat, serta algoritma CatBoost yang sangat baik dalam menangani data non-numerik dan mengurangi *overfitting.* Hasil evaluasi menunjukkan bahwa Stacking Ensemble mencapai akurasi 94.46%, dengan nilai *recall* kelas 1 sebesar 0.94, menunjukkan performa yang sangat konsisten pada kedua kelas.

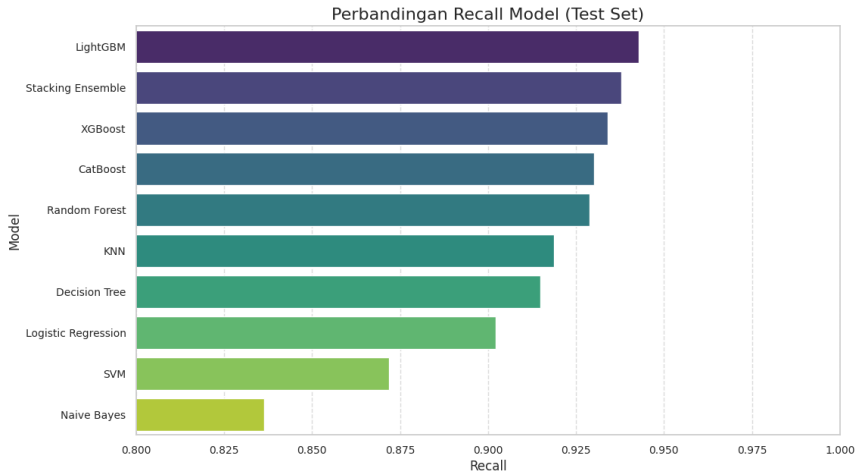

Gambar 8. Grafik Perbandingan *Recall* Kelas 1 dari Sepuluh Model

Dari sepuluh model yang telah dijalankan, hasil *recall* pada kelas 1 dibandingkan satu sama lain. Perbandingan ditunjukkan oleh Gambar 8 di mana model LightGBM terbukti lebih unggul dibandingkan kesembilan model lainnya. Setelah menentukan bahwa LightGBM merupakan model dengan performa terbaik berdasarkan recall untuk kelas 1, dilakukan analisis lanjutan untuk membandingkan variasi model LightGBM. Tabel 5 menyajikan perbandingan nilai precision, recall, dan F1-score antara LightGBM, LightGBM dengan 10-fold cross-validation, serta LightGBM yang telah melalui proses tuning dengan RandomizedSearch.

Tabel 5. Perbandingan Model LightGBM untuk Kelas 1

Nomor	**Metode**	**Precision**	**Recall**	**F1-Score**
1	LightGBM	0,9452	0,9428	0,944
1	LightGBM dengan CV (k=10)	0,9478	0,9428	0,943
2	LightGBM dengan tuning	0,9478	0,9454	0,9466

Hasil perbandingan ketiga model tersebut disajikan pada Tabel 5 dan memperlihatkan bahwa LightGBM dengan tuning memberikan performa paling optimal, dengan nilai *precision* sebesar 0,9478, *recall* 0,9454, dan F1-score 0,9466, sedikit lebih unggul dibandingkan dua model lainnya. Berdasarkan hasil tersebut, LightGBM dengan tuning dipilih sebagai model terbaik dan digunakan sebagai model final dalam penelitian ini. Model ini kemudian dievaluasi lebih lanjut untuk memberikan gambaran performa pada seluruh kelas.

Tabel 6. *Classification Report* Model LightGBM dengan Tuning

	precision	*recall*	F1-score	*support*
0	0,95	0,96	0,95	927
1	0,95	0,95	0,95	788
accuracy			0,95	1715
Macro avg	0,95	0,95	0,95	1715
Weighted avg	0,95	0,95	0,95	1715

Model LightGBM dengan tuning menunjukkan performa yang baik dan seimbang pada kedua kelas. Berdasarkan *classification report* yang ditunjukkan pada Tabel 6, nilai *precision*, *recall*, dan F1-score untuk kelas 0 dan kelas 1 sama-sama berada pada angka 0,95, yang menandakan bahwa model mampu melakukan klasifikasi secara konsisten tanpa bias terhadap salah satu kelas. Nilai *precision* menandakan bahwa sebagian besar prediksi kelas 1 yang dibuat oleh model benar-benar dari kelas 1. Sementara itu, *recall* 0,95 menunjukkan bahwa model mampu

menangkap sebagian besar data kelas 1. Secara keseluruhan, nilai akurasi sebesar 0.95 mengonfirmasi bahwa 95% prediksi model pada data uji adalah benar.

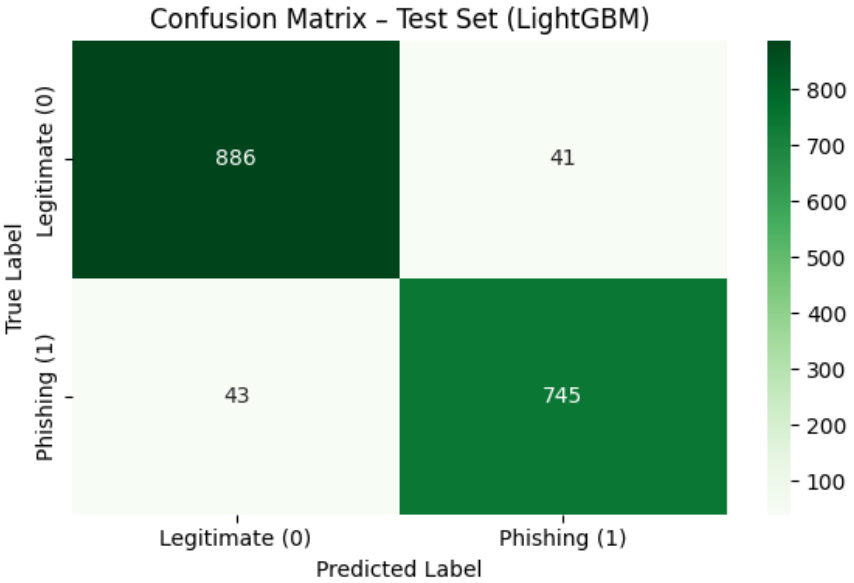

Gambar 9. *Confusion Matrix* Model LightGBM dengan Tuning

Hasil tersebut diperkuat oleh confusion matrix yang ditunjukkan pada Gambar 9. Pada kelas legitimate (0), dari total 927 sampel, sebanyak 886 data berhasil diklasifikasikan dengan benar, sementara 41 data mengalami kesalahan prediksi sebagai phishing. Pada kelas phishing (1), dari 788 sampel, sebanyak 745 data terklasifikasi dengan benar dan hanya 43 data yang salah diprediksi sebagai legitimate. Jumlah kesalahan yang relatif rendah pada kedua kelas menunjukkan bahwa model LightGBM hasil hyperparameter tuning memiliki performa yang seimbang serta kemampuan generalisasi yang baik pada data uji.

Secara keseluruhan, hasil evaluasi ini menegaskan bahwa LightGBM dengan tuning merupakan model terbaik dalam penelitian ini, karena menawarkan akurasi tinggi, stabilitas performa antar kelas, serta kemampuan deteksi kelas positif yang kuat yang sangat penting terutama pada kasus klasifikasi biner yang sensitif terhadap kesalahan pada kelas tertentu.

Diskusi

Hasil penelitian ini menunjukkan bahwa LightGBM dengan tuning mampu mencapai precision 0,9478, recall 0,9454, dan F1-score 0,9466, meskipun hanya menggunakan enam variabel prediktor. Hasil ini menjadi menarik ketika dibandingkan dengan penelitian-penelitian sebelumnya yang umumnya menggunakan jumlah fitur jauh lebih banyak.

Studi oleh Ahammad dkk. (2022) menggunakan 15 fitur terkait struktur URL, DNS, dan statistik domain, namun LightGBM pada penelitian tersebut hanya mencapai akurasi 0,860. Jika dibandingkan, performa penelitian ini lebih tinggi meskipun jumlah fitur yang digunakan kurang dari setengah fitur mereka. Hal ini mengindikasikan bahwa pemilihan fitur yang tepat serta preprocessing yang lebih optimal dapat menghasilkan model yang lebih efisien tanpa harus memperbanyak variabel.

Penelitian Sanchez-Paniagua dkk. (2022) menggunakan pendekatan yang jauh lebih kompleks, yaitu puluhan fitur statistik, karakter URL, entropy, token deteksi login, hingga TF-IDF berbasis teks. Pada dataset besar (90.000 URL), mereka melaporkan akurasi mencapai 96-97% dengan kombinasi TF-IDF dan Logistic Regression, sementara model LightGBM hanya berada pada kisaran akurasi 92-94%. Jika dibandingkan, performa model LightGBM dalam penelitian ini

(F1-score 0,9466) mendekati performa model terbaik mereka meskipun hanya menggunakan enam fitur. Hal ini menunjukkan bahwa efektivitas model tidak selalu ditentukan oleh banyaknya fitur, tetapi oleh relevansi fitur terhadap karakteristik phishing.

Sementara itu, penelitian Alamri dkk. (2025) menggunakan dataset sangat besar dengan 89-112 fitur, serta menerapkan stacking ensemble multi-model yang mampu mencapai akurasi hampir sempurna (99-100%). Dengan kompleksitas yang tinggi, wajar jika performanya unggul jauh dibanding satu model saja. Namun, ketika dibandingkan pada tingkat model klasifikasi dasar, performa LightGBM pada penelitian ini berada dalam rentang yang kompetitif, terutama mengingat bahwa penelitian ini tidak menggunakan ensemble dan menggunakan fitur yang sangat minimalis.

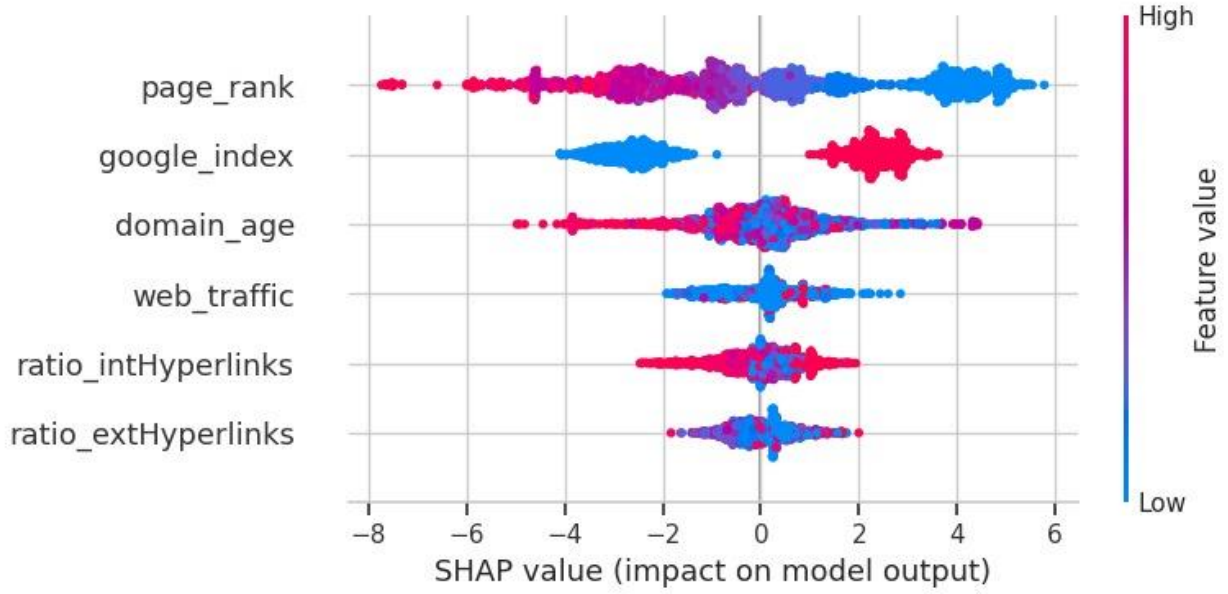

Gambar 10. Plot SHAP

Plot SHAP ini menunjukkan bahwa URL legitimate (biru) dan phishing (merah) dibedakan terutama oleh otoritas dan visibilitas domain. Fitur page_rank paling berpengaruh: nilai page rank tinggi (biru) mendorong prediksi ke legitimate, sedangkan page rank rendah (merah) kuat mengarah ke phishing. google_index juga jelas: URL yang terindeks Google (biru) cenderung legitimate, sementara yang tidak terindeks (merah) meningkatkan probabilitas phishing. Pada domain_age, domain yang lebih tua berkontribusi ke legitimate, sedangkan domain muda lebih sering diasosiasikan dengan phishing. web_traffic memperkuat pola ini, di mana trafik tinggi mendukung legitimate dan trafik rendah mengarah ke phishing. Sementara itu, ratio_intHyperlinks dan ratio_extHyperlinks berpengaruh lebih kecil, namun rasio tertentu terutama penggunaan hyperlink eksternal yang tidak wajar namun tetap mendorong prediksi ke phishing. Secara keseluruhan, model sangat mengandalkan sinyal reputasi dan kepercayaan domain untuk membedakan URL phishing dan legitimate.

Dalam pembangunan dan evaluasi model prediksi, analisis ambiguitas pada setiap variabel perlu dilakukan karena tidak semua variabel selalu memberikan pengaruh yang konsisten terhadap hasil prediksi. Hal ini dapat dilihat pada plot SHAP (Gambar 10) yang menunjukkan bahwa kontribusi masing-masing variabel terhadap prediksi kelas phishing (1) dan legitimate (0) tidak selalu searah. Pada beberapa variabel, nilai fitur yang serupa dapat mendorong prediksi ke kelas yang berbeda, sehingga menyebabkan tumpang tindih antara data phishing dan legitimate. Kondisi ini menunjukkan adanya ambiguitas, di mana model menjadi sulit membedakan kedua kelas secara

tegas. Akibatnya, muncul kesalahan prediksi berupa False Positive, yaitu situs legitimate yang diprediksi sebagai phishing, serta False Negative, yaitu situs phishing yang diprediksi sebagai legitimate. Oleh karena itu, analisis ambiguitas dilakukan untuk melihat sejauh mana masing-masing variabel memberikan pengaruh yang konsisten terhadap keputusan model, sebagaimana ditunjukkan pada Gambar 10 dan dirangkum pada Tabel 7.

Tabel 7. Statistik Ringkas Analisis Ambiguitas Variabel Berdasarkan Kelompok Prediksi

Group	Feature	Count	Mean	Median	Std	Q25	Q75
FP	domain_age	41	0,187	0,116	0,192	0,001	0,325
FN	domain_age	43	0,221	0,204	0,194	0,018	0,4
Correct	domain_age	1631	0,324	0,312	0,237	0,108	0,551
FP	web_traffic	41	0,136	0,004	0,261	0	0,117
FN	web_traffic	43	0,081	0,003	0,172	0	0,043
Correct	web_traffic	1631	0,08	0	0,182	0	0,042
FP	google_index	41	0,707	1	0,461	0	1
FN	google_index	43	0,256	0	0,441	0	0,5
Correct	google_index	1631	0,542	1	0,498	0	1
FP	page_rank	41	0,193	0,2	0,171	0	0,2
FN	page_rank	43	0,256	0,3	0,152	0,2	0,4
Correct	page_rank	1631	0,319	0,3	0,259	0,1	0,5
FP	ratio_extHyperlinks	41	0,23	0,052	0,33	0	0,308
FN	ratio_extHyperlinks	43	0,27	0,158	0,273	0,028	0,5
Correct	ratio_extHyperlinks	1631	0,279	0,132	0,318	0	0,478
FP	ratio_intHyperlinks	41	0,575	0,75	0,422	0	0,964
FN	ratio_intHyperlinks	43	0,66	0,767	0,32	0,393	0,91
Correct	ratio_intHyperlinks	1631	0,609	0,75	0,372	0,269	0,942

Secara umum, tabel ini membandingkan distribusi nilai tiap fitur pada tiga kondisi: prediksi benar (Correct), kesalahan FP dan FN.Variabel yang konsnisten biasanya menunjukkan pergeseran median dan rentang kuartil (q25–q75) antara FP/FN dibanding Correct, sedangkan variabel yang ambigu cenderung punya nilai yang tumpang tindih. Variabel domain_age menunjukkan pola yang cukup jelas di mana median Correct (0,312) lebih tinggi dibanding FP (0,116) dan FN (0,204). Ini mengindikasikan bahwa domain yang lebih tua lebih sering diasosiasikan model sebagai legitimate, sedangkan domain yang lebih muda cenderung mengarah ke phishing. Namun, karena FN masih berada di rentang menengah, ini menandakan adanya kasus phishing dengan umur domain yang tidak terlalu muda sehingga berpotensi lolos sebagai legitimate.

Fitur web_traffic terlihat paling ambigu, karena median semua grup mendekati nol (FP 0,004; FN 0,003; Correct 0), dan q25 juga sama-sama 0. Artinya, nilai web traffic pada banyak data tidak cukup membedakan phishing dan legitimate, sehingga kontribusinya terhadap penjelasan FP atau FN relatif kecil. Variabelgoogle_index merupakan variabelpaling kontras antar grup. Median FP dan Correct sama dengan 1, sedangkan FN sama dengan 0. Ini berarti banyak kasus FN terjadi pada phishing yang tidak terindeks Google, sementara data yang benar (Correct) dan banyak FP cenderung terindeks. Pola ini menunjukkan bahwa status terindeks/tidak terindeks bisa menjadi sinyal kuat, tetapi juga bisa memunculkan ambiguitas ketika fitur lain membuat situs phishing terlihat normal.

Fitur page_rank memperlihatkan bahwa FP memiliki nilai lebih rendah (median 0,2) dibanding FN dan Correct (median 0,3). Ini mengarah pada interpretasi bahwa page rank yang rendah cenderung membuat situs terlihat mencurigakan atau memicu FP, sementara nilai yang

lebih tinggi lebih sering terkait prediksi legitimate dari suatu URL. Sedangkan fitur ratio_extHyperlinks menunjukkan FP memiliki median paling rendah (0,052) dibanding FN (0,158) dan Correct (0,132). Ini dapat diartikan bahwa rasio external hyperlink yang sangat rendah pada beberapa data dapat membuat model cenderung mengarah ke prediksi phishing (memicu FP), sedangkan FN dan Correct lebih mirip sehingga pada variabel ini potensi tumpang tindih tetap ada. Sementara itu ratio_intHyperlinks cenderung tinggi di semua grup (median 0,75–0,767), tetapi FN punya q25 lebih tinggi (0,393) dibanding Correct (0,269) dan FP (0). Ini menunjukkan adanya subset phishing (FN) yang memiliki struktur internal link cukup normal, sehingga lebih mudah terbaca sebagai legitimate dan meningkatkan risiko FN.

Kesimpulan

Penelitian ini bertujuan untuk mengembangkan model deteksi URL *phishing* yang akurat dengan memanfaatkan dataset berdimensi tinggi yang berisi 11.430 URL dan 87 fitur yang mencakup struktur URL, konten HTML, atribut domain, serta informasi reputasi eksternal. Eksperimen terhadap sembilan algoritma *machine learning* menunjukkan bahwa model berbasis *boosting*, khususnya LightGBM, XGBoost, dan CatBoost, memiliki performa yang lebih unggul dibandingkan model klasik seperti Naive Bayes, Logistic Regression, atau SVM. Dari seluruh model yang diuji, LightGBM menjadi model dengan *recall* tertinggi untuk kelas *phishing*, bahkan mengalahkan *stacking*. Nilai ini semakin meningkat setelah dilakukan *10-fold cross-validation* dan *hyperparameter tuning* menggunakan *RandomizedSearch*. Model LightGBM hasil tuning memperoleh *precision* sebesar 0,9478, *recall* sebesar 0,9454, dan *F1-score* sebesar 0,9466 untuk kelas *phishing*, serta akurasi keseluruhan sebesar 0,95.

Berdasarkan hasil pengujian dan analisis interpretabilitas menggunakan SHAP, dapat disimpulkan bahwa model deteksi phishing yang dibangun telah mampu mengidentifikasi pola-pola utama pada URL, namun kontribusi beberapa variabel masih menunjukkan ketidakkonsistenan. Hal ini terlihat dari adanya tumpang tindih pengaruh fitur pada kelompok prediksi benar maupun pada kasus False Positive dan False Negative. Temuan ini menunjukkan bahwa meskipun model memiliki performa yang baik, masih terdapat batasan dalam kemampuan generalisasinya ketika dihadapkan pada karakteristik data yang beragam.

Oleh karena itu, untuk penelitian selanjutnya disarankan agar model diuji menggunakan dataset yang berbeda dan lebih terbaru, mengingat pola domain dan teknik phishing terus berubah dari waktu ke waktu. Pembaruan model secara berkala juga perlu dilakukan agar sistem deteksi tetap adaptif terhadap dinamika serangan phishing. Selain itu, pemanfaatan analisis SHAP sebaiknya terus dilanjutkan untuk memantau perubahan pengaruh variabel dan memastikan bahwa keputusan model tetap dapat dipahami serta relevan untuk diterapkan dalam lingkungan keamanan siber.

Daftar Pustaka

Adane, K., Beyene, B., & Abebe, M. (2023). *Single and hybrid-ensemble learning-based phishing website detection: Examining impacts of varied nature datasets and informative feature selection technique*. Digital Threats: Research and Practice, 4(3), Article 46, 1–27. https://doi.org/10.1145/3611392

Ahammad, S. H., Kale, S. D., Upadhye, G. D., Pande, S. D., Babu, E. V., Dhumane, A. V., & Bahadur, D. K. J. (2022). *Phishing URL detection using machine learning methods*. Advances in Engineering Software, 173, 103288. https://doi.org/10.1016/j.advengsoft.2022.103288

Al-Mekhlafi, Z., Mohammed, B., Al-Sarem, M., Saeed, F., Al-Hadhrami, T., Alshammari, M., Alreshidi, A., & Al-Shaibani, B. (2021). *Phishing websites detection by using optimized*

stacking ensemble model. Computer Systems Science and Engineering, 41(1), 109–125. https://doi.org/10.32604/csse.2022.02041

Alamri, Z., Alhuzali, A., Alsulami, B., & Alghazzawi, D. (2025). *Enhanced phishing website detection using optimized ensemble stacking models.* International Journal of Advanced Computer Science and Applications, 16(8). https://doi.org/10.14569/IJACSA.2025.01608100

Alheyasat, O. (2025). *Web Phishing Detection and Awareness Utilizing Hybrid Machine Learning Algorithms*. International Journal of Advanced Scientific Computing Applications, 2(15). https://www.i-csrs.org/Volumes/ijasca/2025.2.15.pdf

Aljofey, A., Jiang, Q., Rasool, A., Chen, H., Liu, W., Qu, Q., & Wang, Y. (2022). An effective detection approach for phishing websites using URL and HTML features. Scientific Reports, 12, 8842. https://doi.org/10.1038/s41598-022-10841-5

Alsharaiah, M., Abu-Shareha, A., Abualhaj, M., Baniata, L., Adwan, O., Al-Saaidah, A., & Oraiqat, M. (2023). *A new phishing-website detection framework using ensemble classification and clustering*. International Journal of Data and Network Science, 7(2), 857–864.

Al Saedi, M., & Flayh, N. A. (2023). *Phishing website detection using machine learning: A review. Wasit Journal for Pure Sciences.* https://doi.org/10.31185/wjps.145

Alzboon, M. S., Al-Batah, M. S., Alqaraleh, M., Alzboon, F., & Alzboon, L. (2025). *Phishing website detection using machine learning*. Gamification and Augmented Reality. https://doi.org/10.56294/gr202581

Alzubi, R., Bishtawi, T., & Kassem, H. (2025). *Improving web security through machine learning: A feature-based methodology for detecting phishing URLs*. Engineering Technology & Applied Science Research, 15(5), 26845–26851. https://doi.org/10.48084/etasr.12015

Awasthi, A., & Goel, N. (2022). *Phishing website prediction using base and ensemble classifier techniques with cross-validation*. Cybersecurity, 5(1), 22. doi:10.1186/s42400-022-00126-9

Bari, N., Saleem, T., Shah, M., Algarni, A., Patel, A., & Ullah, I. (2025). *A filter-based feature selection framework to detect phishing URLs using stacking ensemble machine learning*. Computer Modeling in Engineering & Sciences, 145(1), 1167–1187. https://doi.org/10.32604/cmes.2025.070311

Barik, K., Misra, S., & Mohan, R. (2025). *Web-based phishing URL detection model using deep learning optimization techniques*. Data Science and Engineering. https://doi.org/10.1007/s41060-025-00728-9

Bourigue, R., Ait Omar, D., & Zougagh, H. (2025). *Improving online security: a deep learning model for phishing URL detection*. Cluster Computing, 28(10), 631.

Calzarossa, M. C., Giudici, P., & Zieni, R. (2023). *Explainable machine learning for phishing feature detection*. Quality and Reliability Engineering International. https://doi.org/10.1002/qre.3411

Ghosh, S., & Singh, D. (2023). *Hybrid-ensemble learning for phishing website detection*. E3S Web of Conferences, 412, 01037. https://www.e3s-conferences.org/articles/e3sconf/pdf/2023/67/e3sconf_icmpc2023_01037.pdf

Hannousse, A., & Yahiouche, S. (2021). *Web page phishing detection* (Version 3) [Data set]. Mendeley Data. https://doi.org/10.17632/c2gw7fy2j4.3

Haq, Q. E. U., Faheem, M. H., Alshingiti, Z., Al-Muhtadi, J., & Saleem, K. (2024). *Phishing URL detection based on a 1D convolutional neural network.* Applied Sciences, 14(22), 10086. https://doi.org/10.3390/app142210086

Islam, M. R., Khan, R., & Rahman, M. M. (2023). *Phishing detection with advanced URL and HTML-based features.* Sensors, 23(19), 8070. https://www.mdpi.com/1424-8220/23/19/8070

Jalil, S., Usman, M., & Fong, A. (2022). *Highly accurate phishing URL detection based on machine learning*. Journal of Ambient Intelligence and Humanized Computing. https://doi.org/10.1007/s12652-022-04426-3

Khaldi, M., Maakhoul, A., & Demerjian, J. (2025). *Hyperparameter optimization for malicious URL detection: Leveraging Optuna and random search in machine learning and deep learning models*. Informatica, 49(1).

Mosa, D. T., Shams, M. Y., Abohany, A. A., El-Kenawy, E. M., & Thabet, M. (2023). *Machine learning techniques for detecting phishing URL attacks*. Computers, Materials & Continua, 75(1), 1271–1290. https://doi.org/10.32604/cmc.2023.036422

Nugraha, M. A., & Susanto, T. D. (2023). *URL-based machine learning classification for phishing detection*. EMACS Journal. https://journal.binus.ac.id/index.php/EMACS/article/view/9951/4808

Omari, K. (2023). *Comparative study of machine learning algorithms for phishing website detection*. International Journal of Advanced Computer Science and Applications, 14(9), 417–425.

Prakongsin, S., & Kanjanasurat, I. (2025). *A comparison of machine learning models based on feature variations for phishing URL detection.* In Proceedings of the 2025 9th International Conference on Intelligent Systems, Metaheuristics & Swarm Intelligence (pp. 51–57). ACM. https://doi.org/10.1145/3760622.3760637

Ramesh, P., & Reddy, N. (2022). *Hybrid feature selection for phishing URL detection*. Journal of Ambient Intelligence and Humanized Computing, 13(10), 4235–4250. https://doi.org/10.1007/s12652-022-04426-3

Rani, S., & Foozy, C. F. M. (2023). F*eature selection to enhance phishing website detection based on machine learning*. Engineering, Technology & Applied Science Research, 13(4). https://publisher.uthm.edu.my/ojs/index.php/jscdm/article/view/13484

Sanchez-Paniagua, M., Fernandez, E. F., Alegre, E., Al-Nabki, W., & Gonzalez-Castro, V. (2022). *Phishing URL detection: A real-case scenario through login URLs.* IEEE Access, 10. https://doi.org/10.1109/ACCESS.2022.3168681

Sari, R. N., & Wijaya, H. (2024). *Comparative study of classification algorithms for phishing URL detection.* EMACS Journal. https://journal.binus.ac.id/index.php/EMACS/article/view/11844

Sharma, V., & Gupta, R. (2022). *Enhanced phishing detection system using machine learning algorithms.* Security and Communication Networks, 2022, Article ID 3241216. https://doi.org/10.1155/2022/3241216

Wahyudi, S. (2022). *Website Phishing Detection Application Using Machine Learning.* IAIC Transactions on Sustainable Digital Innovation, 3(3), 272–282.

Yu, S., Zhang, L., & Tan, C. (2023). *Deep learning-based adaptive phishing URL detection.* Computers & Security, 131, 103545. https://doi.org/10.1016/j.cose.2023.103545

Lampiran

Kode:
https://colab.research.google.com/drive/1SvkjkrL67VGvOeePUUnwBtWYffAunrWk?usp=sharing
Data:
https://data.mendeley.com/datasets/c2gw7fy2j4/3